6G 内生智能与信道基础模型

徐树公　　蒋骏
西交利物浦大学　上海大学

摘要

人工智能（Artificial intelligence, AI）与通信的深度结合已成为 6G 的关键目标和标志之一。内生智能 （Native AI）被认为是 6G 重要特征。本文在给出对内生智能理解探讨的基础上总结无线 AI 研究范式演进，指出基于监督学习的传统 AI 模型存在诸多局限，使其很难作为未来 6G 内生智能的重要组成部分。基于此，我们提出了信道基础模型（Channel Foundation Models, CFMs）并系统地介绍了其预训练方法，以及对各类信道相关任务的可能适配。作为对“什么是内生智能，什么样的 AI 能力是未来 6G 系统需要的”等问题的探讨和分享，我们认为 6G 内生智能需要具备强大任务适应性和场景泛化能力，CFMs 有可能成为未来 6G 内生智能的技术选项之一。

关键词

6G 内生智能；信道基础模型；掩码重建；对比学习；通感一体化；自监督学习；

Abstract：

The integration of Artificial Intelligence (AI) and communication has emerged as a key target and hallmarks for sixth-generation wireless communication systems. Based on the discussion of the understanding of Native AI and the summary of the evolution of AI research paradigms in wireless communications, this paper points out that traditional task-specific AI models have various limitations, making them hardly serve as an important component of future 6G Native AI. Accordingly, we propose Channel Foundation Models (CFMs) and systematically introduce their pretraining methods, as well as their potential adaptation to various channel-related tasks. As an exploration and sharing on issues such as "what is Native AI" and "what kind of AI capabilities future 6G systems need", we argue that 6G Native AI must possess strong task adaptability and scenario generalization ability, and CFMs are expected to become one of the technical options for future 6G Native AI.

Keywords：

6G native AI, Channel foundation models, masked channel modeling, contrastive learning, integrated sensing and communication, self-supervised learning

1 引言

将人工智能（Artificial intelligence, AI）能力应用到移动通信系统的各个部分已经被广泛研究。随着 ITU 6G 愿景将 AI 定义为一项 6G 基本能力，内生智能（Native AI）被认为是 6G 重要特征， AI 与通信的深度结合已成为 6G 的关键目标和标志之一。然而，什么是内生智能，什么样的 AI 能力是未来 6G 系统需要的，目前并没有太多共识。本文尝试分享我们对这些问题的认识。

我们认为所谓内生智能是系统自带的 AI 能力。6G 内生智能需要在系统设计之初就作为系统的核心部分被规划、被设计、被优化、被交付，作为系统不可或缺的一部分存在。 可以将内生类比为汽车的前装组件，在出厂时就已成为交付的（不能轻易拆解的）一部分，区别于用户拿到车之后到 4S 店加装的某些后装组件（非内生）。正因为不太能靠打补丁的方式提供内生智能，我们需要深入讨论，什么样的 AI 能力才是未来 6G 系统需要的，什么样的 AI 能力才有可能未来 6G 系统的核心组件。

目前 6G 研究如火如荼，关于 AI 的标准化研究也已开始。从 6G 应用场景特性来看，其需实现地面、空基、卫星等多域融合通信，信道环境呈现动态时变、异构干扰复杂等特征，且涵盖信道估计、波束赋形、通感一体化等多样化任务，单一任务或场景下的专用 AI 技术，无法适配系统全域部署与灵活扩展需求。若内生智能缺乏任务适应性，将导致网络架构因专用模型激增而臃肿；缺乏场景泛化能力，则难以应对跨域信道特性差异带来的性能波动，这与内生智能作为“系统核心组件”的定位相悖。

下文将通过梳理无线通信领域 AI 研究范式的演进历程，系统剖析传统 AI 模型的局限，再给出一种面向信道的专用基础模型的定义，以及它们的面向多种下游任务的适配能力，探讨其作为 6G 内生智能核心支撑技术的可行性。

2 AI 赋能无线通信的范式演进

回顾将 AI 应用到无线通信中的研究[1-2]，基本和 AI 本身研究范式的发展历程一致。从早期单任务监督学习模式，到多任务协同建模，再到预训练基础模型驱动的范式革新。传统 AI 模型在支撑 6G 内生智能需求方面逐渐显露出诸多难以逾越的局限，这些局限使其难以成为未来 6G 内生智能的重要组成部分。

AI 研究范式的演进大致可分为三个阶段如图 1 所示。第一阶段为单任务监督学习，研究聚焦于以 “一个任务、一个数据集、一个模型” 的模式，模型主要采用端到端方式针对特定任务训练。此类模型的性能高度依赖带标签数据的质量与数量，当数据集不足时易面临过拟合问题，且跨任务迁移能力天然受限。随着应用场景复杂度提升，研究者提出了含共享参数的多任务学习框架。该框架通过联合训练利用任务间共性实现知识迁移[3-4]。然而，多任务学习仍需任务间存在统计相似性，且依赖任务专用架构设计。基础模型（Foundation Models, FMs）的出现标志着深度学习范式的根本性变革，其“预训练模型 + 微调”的两阶段方法彻底革新了领域发展。先基于大规模无监督数据集进行预训练，构建具备泛化能力的基础模型，再通过下游任务的轻量级微调，高效适配多样化的下游任务以及应用场景。在这一演进过程中，传统 AI 模型依赖大量带标签数据、泛化能力不足等固有局限愈发凸显。

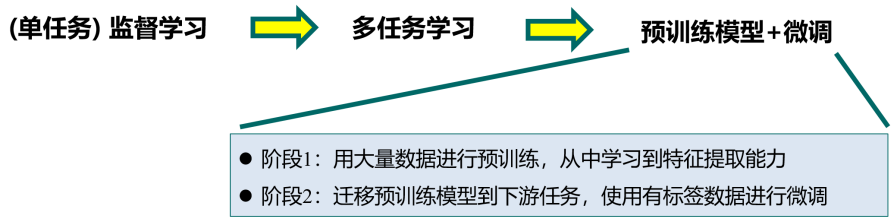

图 1 AI 研究范式的发展路线

传统基于监督学习的 AI 模型存在三大核心局限，严重制约了其在 6G 内生智能中的应用。首先是严重依赖带标签数据。多数传统 AI 模型要实现可靠性

能，必须以海量带标签数据集为支撑。在动态变化的无线环境中，传输模式、干扰时刻变动，稳定采集符合要求的数据集难度极大。更关键的是，人工标注数据过程不仅耗时费力，还容易出现标注错误，进一步增加了资源消耗。

其次是泛化能力有限。6G 需要融合地面、海上、空中等多场景通信，对模型的跨场景适配能力提出了极高要求。但传统 AI 模型在训练过程中极易对训练数据产生过拟合现象，在训练场景中能够表现出较好性能，可一旦进入新场景，性能便会显著下降。

最后是任务专用化设计。6G 中的每个应用场景都需要为传统 AI 模型进行定制化设计，导致任务专用模型数量激增。这大幅增加了整个链路的复杂度和资源消耗，与 6G 内生 AI 所追求的高效、统一的框架理念相违背。

此外，传统 AI 模型还存在实时自适应能力不足的问题。无线通信环境动态变化，实时自适应是维持模型性能的关键。但在静态条件下训练的传统模型，难以快速适应现实场景中的动态变化，对于自动驾驶、远程医疗等需要近实时响应的 6G 关键应用，会产生极为不利的影响。这些局限共同凸显了开发先进 AI 解决方案以满足下一代无线网络多维度需求的必要性，也为信道基础模型的提出奠定了基础。

3 从基础模型到信道基础模型

受大语言模型与计算机视觉领域成功案例的启发，基础模型基于大规模数据集构建，仅需少量额外数据即可适配特定任务。如图 2 所示，与通用大语言模型的方法不同，无线领域的基础模型通过无线专用数据集预训练，显著提升了在无线通信中的相关性与效率。

受基础模型成功的启发，我们在无线通信领域提出信道基础模型 (Channel Foundation Models, CFMs) 的概念。与信道外推、用户定位等需从零开始设计训练的传统任务专用模型不同，CFMs 遵循 “预训练-微调” 范式：首先在涵盖多传播场景、多频率、多环境条件的大规模信道测量数据上进行预训练，使模型提取通用信道特征并学习无线信道的内在统计特性；随后针对特定无线通信任务，利用小规模任务导向数据集对预训练 CFMs 进行微调。这种方法不仅加速了任务专用模型的开发，还提升了模型在不同无线环境中的泛化性能，有效解决了设计可适配多样化动态信道条件模型的长期挑战。

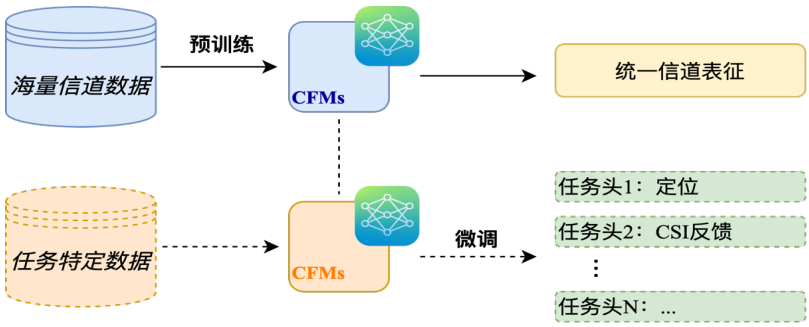

图 2 CFMs 的整体框架图。

凭借这些能力，CFMs 标志着“AI+无线”策略的范式转变，为应对 6G 内生智能的多维度挑战提供一个可行的高效、灵活解决方案。

3.1 信道基础模型的定义

斯坦福大学的 Wiggins 等将基础模型定义为一种在大量原始数据的基础上通过无监督学习训练而成的 AI 神经网络，可适应各种任务[5]，而信道基础模型（Channel Foundation Models, CFMs）是面向无线通信设计的专用基础模型。CFMs 聚焦信道相关特征挖掘与任务适配。不同于无线大模型以“大语言模型，大参数量”为核心支撑，而 CFMs 采用中等参数规模设计，实现信道类任务的精准优化，兼顾模型性能与工程部署效率；预训练模型是“预训练-微调”的通用技术范式，CFMs 则是基于该范式、针对无线信道物理特性定制开发的具体模型，并非所有采用预训练范式的模型（如通用视觉基础模型）均归属于 CFMs。尽管早期有少量工作在无线信道中使用自监督等方法进行表征学习，但他们专注于单一任务，忽略了对信道通用特征的挖掘与跨任务迁移能力的构建，仍未突破传统任务专用模型的局限[6,7]。

具体而言，CFMs 以无线信道为专属核心研究对象，基于大规模异构信道数据开展离线预训练构建而成，其输入输出空间、任务集合均围绕信道特性实现精准界定。输入空间明确以信道状态信息（Channel State Information, CSI）、IQ 信号为主，覆盖多场景、多频段、多环境条件下的异构信道数据；输出空间则聚焦于通用信道特征，通过模型学习实现对信道底层物理规律的精准表征。任务集合严格限定为各类信道相关任务，涵盖两大维度：一是生成任务，包括信道外推、信道估计、信道压缩与反馈、预编码等；二是感知任务，包括场景分类、定位、波束管理等。CFMs 采用神经网络框架，核心目标是学习信道内在物理规律与跨场景通用特征，为上述各类任务提供统一的特征支撑，这与基于通用知识预训练的 LLMs 及传统有监督任务专用模型形成本质区别。

3.2 信道基础模型与其他范式差异

AI 赋能无线通信的主流包括任务专用模型、LLMs 及 CFMs，三者核心特征对比见表 1，结合指标差异可清晰印证 CFMs 作为信道专用范式的必要性。

表 1: 不同范式的对比

	任务专用监督模型	LLMS	CFMS
泛化能力	较差	中等	优异
存储开销	低	高	中等
参数规模	小	极大	中等
预训练需求	无	可选	必须
推理时延	低	高	中等
任务适应性	低	中等	高

泛化能力与预训练需求上，LLMs 预训练可选且以通用知识为核心，未融入信道物理特性，跨场景泛化能力仅达中等；CFMs 则将预训练作为必需环节，基于大规模异构信道数据习得底层规律，泛化能力表现优异。

参数、存储与时延协同优化方面，LLMs 参数规模极大、推理时延久，难以适配边缘部署与实时需求；CFMs 采用中等参数设计，存储与时延均控制在中等水平，通过轻量化微调即可适配任务，平衡性能与部署效率。

任务适应性上，LLMs 需频繁微调，灵活性差；CFMs 依托预训练积累的信道专用特征，微调少量参数即可适配多类信道任务，适应性显著更优。

总的来说，任务专用监督模型与 LLMs 无法均衡满足信道任务需求；CFMs 通过针对性预训练与中等参数设计，构建了更契合信道特性的专用技术范式，使得能成为支撑 6G 内生智能的技术选项之一。

3.3 信道基础模型的核心特征

3.3.1 跨场景与配置的泛化性

传统 AI 模型在无线通信中的核心局限之一是**泛化能力薄弱**，即模型在与训练环境不同的场景中部署时，性能显著下降。传统模型通常基于窄范围场景专用数据集训练，并针对单一任务优化，在面对未见过的场景时性能会出现“灾难性退化”。

在需覆盖地面、空中、卫星通信等异构领域的 6G 中，泛化挑战更为严峻。不同领域具有独特的信号传播特性：多样化环境要求模型能够适配不同的应用场景以及天线配置。

CFMs 通过**高效跨场景泛化**能力应对这一挑战。与传统模型不同，CFMs 的预训练数据集具有大规模异构特性，整合了多场景数据：包括信道模型生成的合成数据、从不同采集的真实测量数据，以及涵盖暴雨、高速移动等极端条件的仿真数据。这种多源数据融合使 CFMs 能够学习无线信道的通用统计规律与跨场景通用特征，从而在多场景中保持稳定性能。

3.3.2 对多下游任务的适应性

CFMs 作为通用信道特征提取器，具备**多下游任务适配能力**——通过轻量化微调即可无缝适配各类信道相关下游任务。这种适应性是基础模型设计的固有属性，通过在大规模多样化数据集上预训练，CFMs 学习到全面的通用特征，仅需少量数据即可高效迁移至特定任务。CFMs 的 “**少样本、低参数**” 适配机制对实际无线系统具有重要意义。与传统监督模型不同，CFMs 仅需少量带标签样本与局部参数调整，即可实现具有竞争力的性能，同时大幅降低计算开销。这一机制有效缓解了部署中的两大核心挑战：

- **数据依赖问题**：无线领域带标签数据的采集耗时且资源消耗大，CFMs 的少样本适配能力满足了该领域的关键实际需求。
- **计算复杂度问题**：低参数微调无需部署阶段的大量计算资源，使 CFMs 可在处理能力有限的边缘设备上应用。

CFMs 的适应性使其成为 6G 通信系统的核心组件，能够在无需构建多专用模型的情况下高效部署于各类任务，为无线通信领域发展提供重要支撑。

3.3.3 可扩展性

可扩展性指“模型性能随模型参数与训练数据集规模增加而稳定提升”的特性，是 CFMs 的核心特征，也是其与传统模型的关键区别。

CFMs 的可扩展性源于基础模型中已被实证的**缩放定律**：随着模型容量与训练数据规模的扩大，模型的表征能力与泛化性能呈现可预测的提升趋势。传统模型的性能通常在模型规模或数据量达到某一阈值后趋于饱和，而 CFMs 遵循完全不同的演进规律，主要体现在模型大小和训练数据两方面：

1. **模型规模可扩展性：**增加 CFMs 的参数数量可显著提升其捕捉细粒度信道动态的能力。大型 CFMs 擅长建模多干扰信号间的非线性交互，其更高的表征精度可实现关键任务的更精准输出。
2. **训练数据可扩展性：**当 CFMs 在涵盖多运营场景、多设备类型、多环境条件的大规模异构数据集上训练时，能够学习更全面的信道特征。这种全方位数据使 CFMs 掌握信道动态的底层规律，从而在所有下游任务中实现更优性能。

4、CFMs 预训练方法

尽管 CFMs 的概念较新且仍处于发展阶段，但现有部分研究在方法设计与应用目标上已与 CFMs 的定义及目标高度契合，值得进行系统性梳理。

为便于分析与对比，本文根据自监督预训练策略，将 CFMs 的预训练方法分为三类：生成式方法、判别式方法及生成-判别混合方法。

4.1 生成式

生成式预训练方法的核心思想是通过建模输入数据的底层分布来学习具有泛化性的特征表征。这类方法通常以重构任务为目标，能有效捕捉信道数据的局部与全局特征，且泛化能力强，能适用于各模态，是一种高效的预训练策略。**其中最典型的就是**掩码重建。该方法如 WiFo[8]和 WirelessGPT[9]通过随机掩码部分 CSI 块，迫使模型学习从残缺输入中重建完整信道特征的能力。掩码策略确保模型能够捕捉信道的全局结构与局部依赖关系，编码器-解码器架构的采用则实现了从特征提取到信号重建的端到端优化。这种生成式预训练方式通过重建损失函数引导模型重建信道，所获特征表示具有更强的语义信息与鲁棒性。

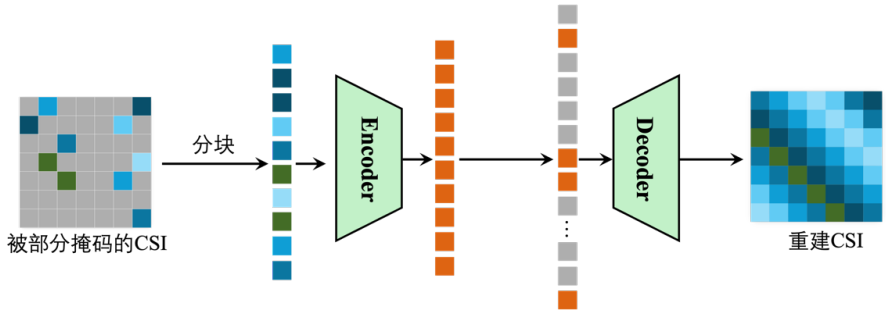

图 3 生成式（掩码重建）的基本流程

4.2 判别式

判别式预训练方法的核心是通过区分不同样本或构建正负样本对来学习**判别性特征表征**。与生成式方法不同，这类方法不依赖数据重构，而是通过衡量样本间的相似性实现训练，因此在部分下游任务中具有更强的泛化性与迁移能力。对比学习作为 CFMs 构建中判别式的核心自监督方法，通过正负样本对，引导模型精准捕捉并区分不同样本。进而学习到更具表征能力的高维信道特征。现有研究中，CSI-CLIP [10]等模型创新性地利用信道数据的时域 -频域对偶特性构建正样本对，通过最大化同类样本相似度、最小化异类样本距离的优化目标，使模型自动捕捉信道的内在物理特性。在下游任务中实现优异性能。

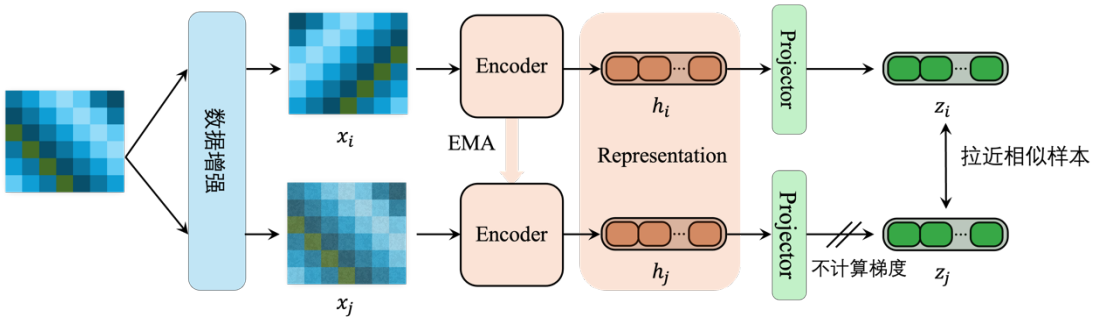

图 4 判别式（对比学习）的基本流程

4.3. 生成-判别混合方法

生成式方法与判别式方法并非互斥关系，反而可形成互补。融合两种范式优势的混合方法，能同时从数据中学习结构信息与判别性特征，从而提升模型的表达能力与泛化能力。该方法融合了生成式与判别式预训练策略的优势，使模型能同时学习丰富的结构特征与判别性特征。此类方法在提升模型泛化能力方面展现出巨大潜力，现有工作[11,12]也已证明混合方法会比单一方法有着更强的性能，有望成为未来 CFMs 研究的重要方向。

5、CFMs 的可能应用及 6G 内生智能

CFMs 凭借其泛化性、适应性与可扩展性，成为 6G 内生智能的重要选项以及 AI 落地的关键载体，在物理层、无线接入网、通感一体化三大核心场景中推动 6G 智能化升级。

5.1 CFMs 赋能物理层

在无线通信物理层的研究与实际部署中， CFMs 凭借其强大的通用特征提取与迁移能力，已成为突破传统技术瓶颈的核心工具。其在信道估计、信道反馈、波束赋形优化等诸多应用场景中展现出显著优势。传统方法通常依赖特定场景下的大量带标签数据进行模型训练。然而，当面临信道环境突变或样本数据稀缺时，这类模型的估计精度会大幅下降，甚至出现失效情况。相比之下，CFMs 作为 6G 内生 AI 的一种可能，通过在涵盖多频段、多地形、多干扰条件的大规模多样化信道场景中进行预训练，能够学习到具有泛化性的信道底层特征。将这些通用特征迁移至特定信道估计任务中，可有效降低模型对目标场景带标签数据的依赖，即便在数据有限或环境动态变化的情况下，仍能保持稳定的估计性能。

5.2 CFMs 赋能无线接入网

无线接入网（Radio Access Network, RAN）作为用户终端与核心网之间的关键接口，其资源调度效率与干扰控制能力直接影响用户体验。CFMs 凭借对复杂网络环境的建模与分析能力，推动 RAN 核心任务的智能化升级，使 RAN 从“被动优化”向“主动自适应”转型。在波束管理中，现有 5G 网络在人口密集城区部署时面临诸多挑战：用户密度高、建筑物遮挡严重、信道条件动态变化快。传统波束选择方法多依赖固定信道模型或简单信号强度检测，易因波束重叠导致小区间干扰，降低网络整体容量。而 CFMs 能够支持的动态波束选择机制则实现了更精细化的优化。此外，CFMs 为 6G 内生 AI 的实现提供了核心技术支撑，推动 RAN 向具备自组织、自优化、自修复能力的更高阶智能形态演进。

5.3 CFMs 赋能通感一体化

在通感一体化领域，通信与感知领域在信号处理目标、特征需求上存在本质差异，通信系统以降低误码率为核心，感知系统以提升定位精度为重点；通信关注信号调制解调特性，感知依赖目标散射特性，这些差异为技术融合带来了巨大挑战。在此背景下，CFMs 凭借对多模态信道特征的统一建模与协同优化能力，成为解决这一难题的变革性方案。在智能交通场景中，基于 CFMs 的融合处理框架可同时提升车辆定位与通信性能。利用多模态信道特征的内在关联性，构建统一的特征表示空间，打破通信与感知技术的壁垒，为 6G 通感一体网络的实际部署提供技术可能。

5.4 CFMs 有效性验证

为验证 CFMs 的有效性、泛化能力及任务适应性，基于 CSI-CLIP，选择 ViT 作为编码器，开展实验验证，引入无预训练的 ViT 模型作为基线模型，以开展对比分析。预训练数据基于 DeepMIMO 数据集构建，包含超过 70 万条样本，覆盖 35 个典型通信场景。该数据集涵盖室内外多类环境，工作频段从 Sub-6 GHz、毫米波延伸至太赫兹，全面覆盖无线通信关键频谱资源，为模型泛化能力的验证提供了充足场景支撑。

表 2: 城市场景下定位性能（误差：米）

场景	微调数据	验证数据	Baseline	CSI-CLIP	性能提升
Philadelphia	503	126	34.1	19.91	**41.61%**
Los Angeles	592	148	49.03	34.18	**30.29%**
New York	1026	257	41.19	36.15	**12.24%**
Columbus	1148	288	17.6	14.48	**17.73%**
San Francisco	1326	332	19.78	14.17	**28.36%**
Austin	1482	371	14.16	8.95	**36.79%**
Phoenix	2163	541	10.65	9.34	**12.30%**
Oklahoma	2764	691	18.87	16.74	**11.29%**
Indianapolis	2720	439	48.08	46.39	**3.51%**
平均	/	/			**21.57%**

如表 2 所示，在定位任务中，当面对有限的新场景微调数据时，CFMs 无需从零开始学习任务特征，仅通过轻量化微调即可将预训练通用特征迁移至定位任务，既大幅降低了对带标签数据的依赖，又有效抑制了小数据量下的过拟合问题。反观无预训练的基线模型，在小数据微调时易陷入过拟合，导致定位误差显著偏高。而随着微调数据量增加，基线模型过拟合现象缓解，但 CFMs 仍有明显性能

增益，进一步印证了预训练特征在小数据场景下的核心价值，为 CFMs 适配无线通信数据稀缺场景提供了实证支撑。

表 3: 波束预测准确率对比

场景	Baseline	CSI-CLIP	**性能提升**
Los Angeles	75.68%	78.38%	**2.70%**
Chicago	87.72%	89.47%	**1.75 %**
Fort Worth	82.94%	84.78%	**1.84%**
Columbus	62.85%	65.63%	**2.78%**
Charlotte	77.53%	80.18%	**2.08 %**
Indianapolis	77.53%	80.18%	**2.65%**

表 3 数据清晰展现了 CFMs 模型（CSI-CLIP）与基线模型在波束预测任务中的性能差异，进一步印证了 CFMs 在信道相关任务中的适配优势。整体而言，CSI-CLIP 在所有 6 个测试场景中均优于基线模型，性能提升幅度介于 1.75%至 2.78%之间，平均提升约 2.3%，体现出 CFMs 通过预训练积累的信道特征对波束预测任务的有效增益。尽管波束预测任务整体性能提升幅度低，但 CFMs 在保持参数规模与推理时延不变的前提下，仍能实现稳定性能增益，进一步验证了其“泛化能力-部署效率”的均衡优势，为 CFMs 作为 6G 内生智能的可能选项技术之一提供实证支撑。

6. 总结

本文首先给出了我们对 6G 内生智能的含义及需求的理解，指出未来 6G 内生智能需要具备强大任务适应性和场景泛化能力。在分析 AI 模型演进范式的基础上指出传统 AI 很难满足这个要求。然后系统介绍了信道基础模型 CFMs 的构建方法和核心技术特征，以及可能应用。随着 6G 内生智能技术的持续演进，我们认为 CFMs 有望成为 6G 内生智能可能技术选项之一，并有望在 6G 通感一体网络等新兴场景中发挥更大作用。

参考文献

[1]Gao, Yuan, et al. "AI-Driven Channel State Information (CSI) Extrapolation for 6G: Current Situations, Challenges and Future Research." *IEEE Communications Surveys & Tutorials* (2026).

[2]Pan, Guangjin, et al. "AI-driven wireless positioning: Fundamentals, standards, state-of-the-art, and challenges." *IEEE Communications Surveys & Tutorials* (2025)

[3] X. Wang *et al*., "Super-Resolution of Wireless Channel Characteristics: A Multitask Learning Model," in *IEEE Transactions on Antennas and Propagation*, vol. 71, no. 10, pp. 8197-8209.(2023)

[4] J. Jiang, et al., "MTCA: Multi-Task Channel Analysis for Wireless Communication," *2025 IEEE 102nd Vehicular Technology Conference (VTC2025-Fall)*, Chengdu, China, (2025), pp. 1-6.

[5]Wiggins, Walter F., and Ali S. Tejani. "On the opportunities and risks of foundation models for natural language processing in radiology." *Radiology: Artificial Intelligence* 4.4 (2022): e220119.
[6] Davaslioglu, Kemal, et al. "Self-supervised RF signal representation learning for NextG signal classification with deep learning." IEEE Wireless Communications Letters 12.1 (2022): 65-69.
[7] Chafaa, Irched, et al. "Self-supervised deep learning for mmWave beam steering exploiting sub-6 GHz channels." IEEE Transactions on Wireless Communications 21.10 (2022): 8803-8816..
[8] Liu, Boxun, et al. "WiFo: Wireless foundation model for channel prediction." Science China Information Sciences 68.6 (2025): 162302.
[9] Yang, Tingting, et al. "Wirelessgpt: A generative pre-trained multi-task learning framework for wireless communication." IEEE Network (2025).
[10] Jiang, Jun, et al. "A mimo wireless channel foundation model via cir-csi consistency." *2025 IEEE International Conference on Machine Learning for Communication and Networking (ICMLCN),* Barcelona, Spain, (2025), pp. 1-6.
[11] Pan, Guangjin, et al. "Large Wireless Localization Model (LWLM): A Foundation Model for Positioning in 6G Networks." *arXiv preprint arXiv:2505.10134* (2025).
[12] Guler, Berkay, Giovanni Geraci, and Hamid Jafarkhani. "Robust Channel Representation for Wireless: A Multi-Task Masked Contrastive Approach." *NeurIPS 2025 Workshop: AI and ML for Next-Generation Wireless Communications and Networking*. (2025).